

深度访谈报告

姚顺宇

语言及世界工作室

张小珺 / 2026-05 / 3h 47m

姚顺宇 on 语言及世界工作室: 深度报告

Guest: 姚顺宇 (Yao Shunyu), Google DeepMind研究员 | Host: 张小珺 | Duration: 3h 47m | Date: 2026-05 | Show: 语言及世界工作室

访谈概览 (Interview Overview)

Guest Bio

姚顺宇是Google DeepMind研究员，从事ML Coding与Long Horizon方向的研究。此前在Anthropic参与大尺度强化学习工作，是Claude 3.7后训练的核心贡献者。他的学术背景独特：清华基科班（凝聚态理论/量子物理方向）毕业后赴斯坦福攻读高能理论物理博士，在伯克利做博后仅两周便转向AI工业界。在清华本科期间，他曾在非厄米量子系统中做出范式级工作，建立了描述开放边界非厄米系统本征态和动力学的新框架。他被认为是物理转AI路径中最成功的代表之一，与另外两位著名的清华系AI研究者（吴永辉、另一姚顺宇）共同构成了硅谷华人AI圈的重要力量。

Interview Context

本访谈发生于2026年中，正值AI行业多项重大变化交汇之时：模型benchmark能力全面趋同、Open Cloud等新AI产品形态引发热议、中国AI公司（字节、DeepSeek等）快速追赶、AI coding革命对程序员职业产生深刻冲击。主持人张小珺借此契机，展开了对姚顺宇约3小时47分钟的深度访谈，覆盖AI行业格局、技术进展、组织文化、个人成长四大板块。

Key Stats

Metric	Value
Total topics covered	12 segments
Total insights extracted	124
Total quotes extracted	130
Notable predictions made	37
Total data points	126
Total contradictions identified	46
Cross-cutting themes	7

执行摘要 (Executive Summary)

本访谈最核心的故事是：AI行业已从一个依赖个人天才英雄主义、注重模型能力追赶的时代，进入了系统性工程、组织文化和定义清晰任务为主导的新阶段。姚顺宇反复用"冲浪"比喻描述这个转变——AI浪潮本身拥有不可阻挡的动量，个人的贡献被严重高估，"这个世界在推着我們前进，而不是我们在推着这个世界前进。"

第二个关键叙事是范式成熟度的分层。姚顺宇将AI领域按成熟度分为三层：自然语言处理（范式确定，工程优化为主）、多模态生成（范式未固定，仍有科学突破空间）、机器人（甚至还没到GPT-1时刻）。这一分层决定了他对各领域进展速度和投资价值的判断：coding发展最快（语言成熟+奖励信号清晰），机器人最慢，而多模态生成是下一个可能产生"英雄集体"的范式突破方向。

第三个贯穿访谈的叙事是组织DNA如何决定AI战略。姚顺宇通过对比Anthropic（top-down、"像一个宗教"地聚焦单一赌注）、Google DeepMind（bottom-up、多方向并行、减少赌的成分）和OpenAI（失去top-down能力后的过渡态），揭示了不同的组织模式如何塑造了完全不同的技术路线和产品策略。他指出Anthropic模式的关键条件是"技术一号位同时是公司决策人"——这在联合创始人团队从OpenAI时代就一起"趴过战壕"的情况下才可能实现，也解释了为什么这种模式极难复制。

话题深度分析 (Topic-by-Topic Deep Dive)

1. 开场与两位姚顺宇 (00:37 – 12:31)

背景

访谈以嘉宾自我介绍和"硅谷两位姚顺宇"的区分开场——一位是物理转AI的嘉宾（Google DeepMind），另一位是CS路径的姚顺宇（清华姚班→普林斯顿→AI）。这个区分不仅涉及身份澄清，更引出对AI行业特质、发展阶段和模型差异化的深层讨论。

核心论点

姚顺宇给出了一系列对AI行业现状的洞察。最核心的观点是：**AI行业最重要的特质不是才智而是"靠谱"**——做事细致、对工作负责任。他用"冲浪"比喻描述个人与时代浪潮的关系："现在就是大家每个人都是冲浪的人，本质上是一个浪，而不是你那个冲浪的人。"这一立场将决定他后续几乎所有的职业判断和组织评价。

关于AI当前阶段，姚顺宇提出了一个关键框架：**核心转变是从"AI能不能做到"到"任务是否被良好定义"**。他对比一年前（2024年初）在Anthropic时的状态——当时大家还担心能否追上OpenAI的reasoning能力——而现在DeepMind、OpenAI、Anthropic三家之间已经没有"谁追不上谁"的焦虑。真正的难点变成了"想明白要去做什么"，这"是一个需要human insight的赌"。

模型基准测试方面，姚顺宇断言公开benchmark上的差异已变成噪声而非信号。他以48H为例：各模型都在80%附近，高一点低一点"主要是噪声"。但实际使用体验仍有区别——Claude在通用工具使用和agent场景最好，Codex在coding方面追近，而DeepMind在纯reasoning日常场景可能仍然领先。过去模型之间的差异主要是"意愿"驱动的——各公司选择专注不同方向——而非纯粹的技术能力差异。现在"模型差异的来源越来越来自想象不到的事"。

KEY QUOTE (00:45):

"AI这个事儿本来也不太需要脑子，太需要脑子，真的不太需要脑子。你需要什么？我觉得这个行业最重要的特质就是靠谱，就是做事儿细，然后对自己做的事儿负责任，这是最重要的特质。"

KEY QUOTE (05:47):

"对我来说确实在AI进入到了一个阶段。我觉得大家都已经开始不那么担心一件事AI是不是能够做得到，而是担心这件事儿是不是被良好定义。"

KEY QUOTE (07:08):

"大家都在80%附近，那个附近数字高一点低一点，其实是主要是noise，就主要是是噪声而不是信号。"

KEY QUOTE (10:17):

"模型好写，代码会写得很好啊，但是可能那时候大家也不知道为什么。但是这个里面意外的原因可能就是 你从网上随便去……从GitHub上取的数据质量是显著比别的正常网页要高的。"

KEY QUOTE (11:26):

"有趣的是我感觉这个事情（Open Cloud）在业外的讨论好像比业内的讨论更激烈。业内没有人讨论，业内有人讨论。但是我觉得对业内的人来说，它并不是一个特别令人惊讶的事。"

数据点

- 嘉宾路径：清华基科班（凝聚态理论）→ 斯坦福高能物理博士（量子信息与黑洞方向）→ 伯克利博后（仅两周）→ Anthropic（约一年）→ DeepMind（2024年9月底/10月初加入）
- 另一姚顺宇：清华姚班（计算机科学实验班）→ 普林斯顿 → AI领域，两人本科同级
- 三大顶级AI实验室：DeepMind（谷歌）、OpenAI、Anthropic
- 模型在48H等主流benchmark上均在80%附近，差异仅1-2个百分点
- 曾用benchmark：SWE-bench（coding）、AIME（数学）、AMC（数学）
- Open Cloud作者已加入OpenAI
- Google内部在Open Cloud发布前已有类似实验或demo

2. AI时代定义与模型商品化 (12:38 – 22:05)

背景

从Open Cloud和Manus的产品现象切入，深入讨论AI应用层的壁垒问题、创业公司生存策略，以及中国AI人才优势。这一部分是访谈中最具实战参考价值的内容之一。

核心论点

姚顺宇对Open Cloud给出了一个分裂的评价：技术上"并不能说明什么"——模型做这些事的能力"在去年就已经准备充足"（Anthropic发布4.5时在tool use上已领先于OpenAI和DeepMind）。但其真正的贡献是"展示了可能性"——让行业意识到可以控制多个不同模型做不同的long-horizon工作。这种认知共识在此前并不存在。

对于Manus与Open Cloud的区别，姚顺宇出乎意料地坦诚："Manus和Open Cloud之间的质的区别是什么？是一个我其实自己没太看明白的事情。"他认为可能只是Manus没选择做而非做不了，暗示行业内对这些产品的定位可能也没有共识。

姚顺宇随后构建了一个清晰的AI壳公司二元生存框架：路径一（Cursor型）——增长速度必须在模型公司追上之前达到逃逸速度并自研模型；路径二（Midjourney型）——市场小到模型公司"看不上"。他量化了两种路径的生存概率：赌大市场约万分之一（1‰），吃小市场约百分之一（1%）。

最引人注目的是关于Cursor与Anthropic竞争关系的揭露：曾经亲密无间的合作伙伴现已进入"非常微妙的关系"——Cursor在自研Composer模型，Anthropic的Claude Code越来越成功。且AI coding效率工具天然倾向于"赢家通吃"的市场结构。

关于ChatGPT的本质，姚顺宇提出了一个挑战流行叙事的判断："除了AI coding之外，没有哪个场景是AI真正原生的、变得非常成功的应用场景——ChatGPT本质上是搜索的延伸。"

关于中国AI人才，姚顺宇做出了一个可能引发争议的论断："中国的本质上人才是比美国要更好的。"这解释了Meta收购位于新加坡的Manus团队的深层逻辑——将其作为吸引中国和东亚AI人才的锚点。

KEY QUOTE (13:43):

"他让大家意识到了这件事可以做……你可以控制很多不一样的模型，然后做很多不一样的事情，然后把这个事情汇总，做一个很长很长老horizon的这种工作。我觉得可能以前大家并没有广泛的对这个事儿产生共识。"

KEY QUOTE (14:20):

"Manus和Open Cloud之间的质的区别是什么？是一个我其实自己没太看明白的事情。说实话OK。我不明白Manus为什么做不了，可能只是他没做对。"

KEY QUOTE (15:14):

"目前来说我觉得没有哪一个场景真正的形成了数据飞轮，甚至AI纯粹原生的应用场景。我觉得目前除了AI coding就是写写代码之外，没有哪个场景是AI真正原生的场景，变得非常成功。因为从某种意义上来说，ChatGPT其实是搜索的一个延伸。"

KEY QUOTE (17:27):

"现在就是Cursor和Anthropic已经进入了一个非常微妙的关系。就是曾经他们是亲密无间的合作伙伴，Anthropic提供模型，Cursor提供产品。后来Cursor有了Claude Code，现在变得非常成功。然后Cursor现在又自己试图做自己的模型，所以Cursor在努力的训他的Composer。"

KEY QUOTE (18:06):

"代码这个事情其实它本质上是一种服务于专业用户的专业需求，是一种工效率工具。效率工具很容易出现的一个场景，就是说赢家通吃。"

KEY QUOTE (18:41):

"这个市场足够的小小到模型公司根本懒得去管。我觉得Made Journey就是这一个例子……足够小，以至于可能咱们俩就不是很会在那上面花時間了，看不上。"

KEY QUOTE (19:51):

"你要不要抱着1‰的生存几率去赌一票大的，还是抱着1%的生存几率去先吃另一个小的事情。"

KEY QUOTE (20:15):

"如果是我，我内心肯定是想吃一票大的，但是我真诚的想是我觉得第一步是不能一步登天的。所以如果是我，我会选择去吃一个先吃一个小的，但是我会选择一个有想象空间的小的。"

KEY QUOTE (21:13):

"中国的AI人才出轨还是很丰富的。虽然可能目前从技术上纯技术上来说，中国的AI还没有真的追上美国。但是显然中国是有很多好的人的，不管是从纯技术上还是从产品上，我觉得可能中国的本质上人才是比美国要更好的。"

数据点

- Anthropic在去年（2024年）发布4.5时，在tool use能力上比OpenAI和DeepMind都强
- Open Cloud发布后并没有立即火，过了一段时间后才受到广泛关注
- Manus卖给了Meta；Open Cloud作者加入了OpenAI；Google收购了Windsurf团队（人才收购）
- Cursor正在自研模型Composer；Claude Code变得非常成功
- Midjourney——AI图像生成领域的成功案例，选择了模型公司不愿进入的小众市场
- Manus团队位于新加坡，成为Meta在亚洲吸引人才的地理锚点

3. Open Cloud与产品形态 (22:14 – 51:20)

背景

深入剖析Open Cloud现象背后的结构性问题——为什么突破性产品来自小团队而非大厂，以及2026年最重要的AI技术叙事是什么。这一部分也是coding革命和AI对工作冲击讨论的密集区域。

核心论点

姚顺宇提出了一个解释大公司为何做不出Open Cloud/Manus的关键框架：大公司做产品有巨大的负担——法律风险、品牌保护、资源承诺。个人开源项目可以说"我代码垃圾又如何，你帮我来一起写"，大公司不能。

关于2026年最重要的技术叙事，姚顺宇给出了明确的答案："模型做到train with finite context, use as infinite context"——用有限context length训练模型，但在使用时实现接近无限的context length。这是解锁个人助手等全新应用的关键方向。

对"模型进步是否放缓"的质疑，姚顺宇给出了系统反驳。他认为声称"scaling law到头了"的人无非三种情况：理论判断、特定瓶颈判断、或者——"自己工作里有bug没发现——第三种情况反而是最常见的。"

他提出了**"算法相变"理论**来类比算法在AI进步中的作用模式：在没有搞清楚怎么做的时候，算法极度关键（如Transformer的发现）；在范式清楚之后，算法变成平滑地提高效率。自然语言生成在科学上比较清楚，但多模态生成"是另一个科学问题还没有解决的领域"。

对coding为什么是AI发展最快的场景：reward signal清晰可定义，以及GitHub提供了几十年优秀程序员的代码数据。

关于AI对程序员工作的冲击，姚顺宇做出了反直觉观察：AI让开发速度提升20到50倍，但工作时间反而变长了——因为速度变快后越想试，工作密度也变高了。他保守估计90%的代码由AI生成。

他认为最终结果可能是"1%的人干了过去所有人的工作"——AI是一个"很centralized的技术，它会让少部分人变得更强，但会让大部分人失去他们的独特价值。"

引人深思的是他对AI能力替代顺序的分析：AI先攻克的是人类觉得最难的那些智力工作（数学、编程、AI研究），因为这些事有客观评价标准。而产品经理这种没有客观评价标准的工作，AI反而做不好。

KEY QUOTE (23:43):

"模型做到train with finite context, use as infinite context。换句话说就是你用有限的context length去训练它，但是可以在使用的时候用非常长，甚至接近于无限的context length。我觉得这件事儿今年是有机会能够做实现的。"

KEY QUOTE (26:26):

"我觉得我个人得到的感受是这个模型学东西的能力越来越强了。以前可能让模型学会干一件事情需要动很多脑筋，但现在可能不需要动那么多脑筋了。最重要的是你是要把这个问题定义清楚，然后想清楚怎么去构建合适的数据。"

KEY QUOTE (29:05):

"很多时候修好一个bug带来的进展是远大于一些很神奇的技巧的。"

KEY QUOTE (33:49):

"人就是这样，就是当你没有撞到头的时候，你其实不知道这个路有多长。我能看到的就是现在还没撞到头，但我也不知道哪天会撞到头。"

KEY QUOTE (38:36):

"真正去输出code，我觉得模型比人的能力强太多了……保守估计模型写的超过90%，不保守的可能就是99或者100。"

KEY QUOTE (39:53):

"我觉得保守估计90%给我自己点面子。"

KEY QUOTE (41:43):

"我觉得开发的速度变快了之后，就越试越想试，有越来越多的想法要去试……你现在看到这个文件，你不懂，拿去问一下Claude或者Gemini，这可能5秒钟就告诉你结果，你就接着干了。"

KEY QUOTE (42:27):

"我觉得在战AI这个领域没有谁可以养老。"

KEY QUOTE (45:10):

"过去大家往往会觉得最智力上有挑战的工作……越是这些事儿其实应该越容易做好。因为你一旦想清楚这个事儿怎么去评价，你就知道怎么训练。"

KEY QUOTE (47:09):

"AI是一个很centralized的technology, 它会让少部分人变得更强, 但会让大部分人失去他们的独特价值。"

KEY QUOTE (46:17):

"做好一个产品经理是一个我现在想不明白该怎么训练AI去做的事儿……没有标准就是没有刻度。"

数据点

- 嘉宾保守估计90%的代码由AI生成, 非保守估计99%或100%
- AI辅助后实验效率提升20到50倍
- 嘉宾典型作息: 早上9点起床, 10点到公司, 晚上10-11点离开
- GitHub汇聚了过去几十年全球优质程序员的代码
- 一年半以前只有Claude一家能真正写软件工程级别的代码
- 未来1%软件工程师完成过去所有人的工作, 拿100倍工资 (嘉宾强调1%是虚数)

4. 中美AI竞争与机器人 (51:29 - 01:09:00)

背景

从中美模型能力差距、蒸馏争议、豆包产品特色, 延伸到机器人进展和Apple AI战略。

核心论点

关于中美差距: "过去一年的发展趋势, 显然中美之间的gap是越变越小了。但是最后这个gap会不会完全弥合, 甚至中国超过去, 那我觉得是一个不清楚的问题。"

算力劣势逼出了蒸馏创新。他区分两种蒸馏: "硬蒸馏" (直接从别家模型取token训练) 是"商业上不道德、智力上愚蠢"的; "软蒸馏" (多模型协作训练) 则"技术上很有意思"。他认为中国实验室可能是真正multi-agent训练的先驱——用不同家的异构模型做训练。

对豆包语音生成能力极度正面: "客气的说可能是全世界最好的之一, 不客气的说就是全世界最好的。"他强调这不是产品层面的事, 一定是模型层面的事。

关于Apple AI战略: Apple一定内心重视AI, 但"如果你外界来看就显得很重视, 还做不成, 那就显得很蠢"——这是一种自我保护的形象管理。

关于吴永辉："他是我见到了少数层级非常高，然后人也很senior，但是还有很强的技术能力，我觉得是非常少见。"

关于机器人进展："机器人我觉得没到那个阶段"——仍处于feature engineering时代，还没有到GPT-1时刻。但机器人实验室"比做语言模型的实验室要有趣的多。"

KEY QUOTE (53:39):

"中国确实在实际的算力资源上来说是占很大劣势的。但是这个很大的劣势可能反而逼出了一些有趣的事儿。比如说中国的模型公司，其实对蒸馏就真的很有研究。"

KEY QUOTE (55:01):

"硬蒸馏就是……从Claude里面取出一堆它生成的token，然后强行在上面做训练。如果干这样的事儿，我就觉得首先商业上也不是很道德了，然后智力上来说也比较愚蠢。"

KEY QUOTE (56:07):

"中国的实验室成为了做multi-agent训练的先驱，而且是真正的multi-agent。因为它如果从不同家的模型里，用这种比较聪明的方案，把它们融汇到一个训练系统里的话，每家模型它可能是分布很不一样。"

KEY QUOTE (01:02:13):

"客气的说可能是全世界最好的之一，不客气的说我觉得就是全世界最好的。"——评价豆包语音生成能力

KEY QUOTE (01:01:23):

"你要让我解释他为什么要从外界来看没那么重视，我的唯一猜测就是如果你外界来看就显得很重视，还做不成，那就显得很蠢。"——论Apple AI战略

KEY QUOTE (01:05:28):

"有没有泛化性，其实是很多AI方向它的一个分水岭。就是一个确定的场景，一个很单一的场景，能不能做好这个事儿，不是最近这几年才解决的，十几年前就能干。"

KEY QUOTE (01:08:30):

"我觉得对我来说不管机器人还是多模态生成都没到这个点——就是大家还没有没有想明白怎么去scale up。"

数据点

- 吴永辉：从Google跳槽至字节跳动的高级技术领导者
- Dario (Anthropic CEO) 点名了三家中国公司在做蒸馏
- 豆包语音生成能力：嘉宾评估为"全世界最好"或"全世界最好之一"
- 中国人形机器人在亚马逊上售价远低于嘉宾预期
- Gemini 3.1在回答同样问题时已比以前快很多、废话少很多
- 嘉宾出生在宁夏大武口——一个因石炭井煤矿而存在的小城市

5. 个人成长：从竞赛到清华 (01:09:31 – 01:19:44)

背景

姚顺宇的成长叙事——从宁夏到上海到北京——是理解他性格底色和决策模式的核心素材。

核心论点

姚顺宇的成长叙事中贯穿着一个强烈的人格主题："Underdog心态"——主动选择不利环境然后从中突破。他选择了格致中学竞赛班而非上海四校普通班："光脚的不怕穿鞋的"。

对他影响最深远的人生经历是为争取清华自主招生考试资格而给招生办老师发短信。在夏令营最后一天听说有面向北京学生的自主招生考试后，他当天就"疯狂给招生办的老师发短信"质问。这次经历让他学到了"人生最重要的道理就是胆子要大。你不争取是永远得不到的，争取了也有可能得不到，但不争取就绝对得不到。"

在家庭关系方面："我一般都是通知。"父母"不太管我"且"管不住"。关于胜负欲："我更多的是在跟自己较劲，不是不太愿意和别人较劲。"

KEY QUOTE (01:11:10):

"我这个人的个性就是总是爱干一些自己不太会的事儿。"

KEY QUOTE (01:11:39):

"我感觉这个竞赛，比方按照现在的话说就是underdog。厉害，用当时话说我感觉就是光脚的不怕穿鞋的，我觉得可以一搞。"

KEY QUOTE (01:12:42):

"就算能上，我也应该去一个underdog地方赌一把。"

KEY QUOTE (01:15:25):

"我从那件事儿得到的人生最重要的道理就是胆子要大。你不争取是永远得不到的，争取了也有可能得不到，但不争取就绝对得不到。"

KEY QUOTE (01:15:49):

"我当时满脑子想的都是现在就得争取，再不争取明天就争取不到了。"

KEY QUOTE (01:18:03):

"我爸妈最好的一点就是他们不太管我，他们可能曾经也试图管过我，后来发现管不住。"

KEY QUOTE (01:18:25):

"我觉得可能大多数中国家庭都是孩子和父母商量已经算是很好的了。我一般都是通知。"

KEY QUOTE (01:18:41):

"当你没有办法理解别人在干什么的时候，别指手画脚。"

KEY QUOTE (01:19:00):

"我很care我想做的事儿。如果这件事儿是我自己想明白了要去做，你就别拦我，然后我也一定会尽最大的努力做到最好。但如果这个事我不想干逼我干也没用，我也不会干。"

KEY QUOTE (01:19:24):

"我更多的是在跟自己较劲，不是不太愿意和别人较劲。当然如果正好是我觉得这事儿很重要，你也觉得这事很重要，那我肯定是要干的比你好。"

数据点

- 初中就读于上南中学东校
- 上海高中有"四校"之说：上海中学、华二、交大附中、复旦附中
- 选择了格致中学竞赛班——在当时比四校"稍微差点的学校"
- 竞赛保送制度变化：入学两届前省一等奖即可保送；到他这届时需要进入国家集训队
- 通过清华自主招生考试获得降至一本线录取资格，而非保送

— 高考分数未达到清华录取线，但"除了清北之外的学校都能上"

6. 物理学的范式与教训 (01:19:49 – 01:42:26)

背景

姚顺宇对其物理学研究经历的深度回顾——从本科在非厄米系统中的范式级工作，到博士在高能理论物理领域的挫败，以及从物理转向AI的根本原因。

核心论点

姚顺宇将物理学研究与AI研究做了根本性的类比："物理科研和AI其实也是一样，AI也是你有一个想法，你有一个理解，你去设计一些实验验证你的理解是不是对的。"

本科期间的非厄米系统发现是范式级别的工作——传统布洛赫波范式在开放量子系统中彻底失效，能量本征态会聚集到体系边缘。

两个关键教训：(1)"读书不在于读得多，而在于读得深"——独特见解才是真正价值；(2)"别太相信纯理论"——理论需要数值和实验的检验。

对博士生涯的评价冷酷而诚实。他直指高能理论物理的根本问题：实验完全追不上理论，方向好坏退化为"领域内一些老登的主观判断"。"人这一辈子也没多长，为什么要把自己的时间浪费在伺候老登身上？"他用"训练模型"的比喻来描述适应一个不认可的评价体系——你知道标准后"做得好是很容易的。"但最终"我蒙蔽不了自己，骗不了自己。"

选择离开凝聚态方向（尽管刚完成范式级工作）也是因为预判后续工作边际价值递减——"后面你再去做一些工作……感觉作为一个科学生涯来说，就没那么令人激动了。"

KEY QUOTE (01:19:56):

"现在回过头来说，当然能编造出一些听起来很合理的理由。但是摸着良心回到当初，我觉得就是阴差阳错。"

KEY QUOTE (01:22:21):

"物理科研和AI其实也是一样，AI也是你有一个想法，你有一个理解，你去设计一些实验验证你的理解是不是对的。然后你设计一些模型上的训练的拍板，来把你的想法实施出来。"

KEY QUOTE (01:26:31):

"抓住一次范式的变化？是的，这就是人性的弱点。就是我感觉我总爱挑战一些自己不会的事儿。"

KEY QUOTE (01:26:48):

"在那个方向，可能那个工作从再过几年回头来看，就会是这个方向最重要的工作。后面你再去做一些工作……感觉作为一个科学生涯来说，就没那么令人激动了。"

KEY QUOTE (01:27:38):

"难听了就是爱折磨自己。说好听的是挑战自己。"

KEY QUOTE (01:27:51):

"如果为了被折磨而被折磨，那这个人就是有心理疾病。但是如果一个人是为了学习更多的东西，丰富自己的经历和能力而被折磨，我觉得是值得的。"

KEY QUOTE (01:35:44):

"读书不在于读得多，而在于读得深。你读的多不代表你能够发现新的东西。但如果你对一件事儿有和别人不一样的见解，那个才是对这个社会来说更有价值的事。"

KEY QUOTE (01:36:11):

"别太相信理论，别太相信纯理论。"

KEY QUOTE (01:38:00):

"当这个领域完全没有实验，没有客观标准的时候，肯定不会只有一个框架出现，肯定不会只有一个自治的框架出现。那这个时候谁做的好，谁做的不好，其实就依赖于领域内一些老登的主观判断。"

KEY QUOTE (01:38:34):

"人这一辈子也没多长，为什么要把自己的时间浪费在伺候老登身上？"

KEY QUOTE (01:38:47):

"花了五年学了很多知识，买了一个大教训。"

KEY QUOTE (01:39:06):

"大教训就是要做实验，要要有做有有比较客观评价标准的事儿。或者从另一个角度来说，就是要做对这个世界能够产生影响的事。"

KEY QUOTE (01:40:06):

"达到外界的标准，会达到一个小的圈子的评价标准，是像训练模型一样。就是一旦有了这么一个小的圈子，你知道他们的评价不标准之后，做得好是很容易的。"

KEY QUOTE (01:40:33):

"我后来就发现我蒙蔽不了自己，骗不了自己。"

KEY QUOTE (01:39:30):

"摸着良心说对这个世界有多大的影响，我觉得几乎没有影响，几乎为零。"

数据点

- 清华物理系基科班（学堂班），该班2/3的学生最终不会做物理
- 清华高等研究院由杨振宁先生创立，姚顺宇在此进行本科科研
- 本科在非厄米系统中完成范式级工作，引发"很多很多follow up的工作"
- 博士在斯坦福攻读高能理论物理，与本科方向"几乎没有任何联系"
- 高能理论物理已发展到实验完全无法验证的阶段
- 伯克利博后实际待了两三个月，但官方记录只有两个星期
- 在博士最后两年开始意识到高能理论的问题，开始了解量子计算/量子信息方向

7. AI认识论：黑盒与科学 (01:42:28 – 01:49:55)

背景

讨论AI作为科学学科的认识论地位，以及物理背景在AI领域过度代表的原因。

核心论点

姚顺宇挑战了"AI是黑盒所以不科学"的观点："我觉得这世界上所有东西都是黑盒。哪怕像物理这种大家觉得很理解的东西，其实也并不是真的有一个从他微观的行为一路演化到了宏观体现的这种理解。"

关于"智能涌现"的批判更加尖锐："首先这个话就不太科学，所以自然也没有办法用科学的话来表达一个不科学的事儿。"

关于scaling law的科学地位：类比热力学历史——scaling law目前是经验规律，但未来可能成为科学规律。热力学第一定律、第二定律等在当年也都是经验规律。

关于物理转AI：硬技能几乎没有转化——真正迁移的是性格：刨根问底和系统性做事。AI领域物理背景过度代表的根本原因是connection（人际网络），而非物理技能独特。

当前AI研究的状态被他类比为18-19世纪的热力学：理论和实验不分家，"你就是搞物理的。"

KEY QUOTE (01:44:31):

"我觉得这世界上所有东西都是黑盒。哪怕像物理这种大家觉得很理解的东西，其实也并不是真的有一个从他微观的行为一路演化到了宏观体现的这种理解。"

KEY QUOTE (01:46:08):

"经验规律和科学规律它之间的界限是很模糊的。比如说我们回头去看这种热力学的定律……这些东西在当年被发现的时候也都是经验规律。但是只是说后来随着时间的发展，我慢慢知道了它的微观机制，它可能变成了一个科学规律。"

KEY QUOTE (01:47:01):

"首先这个话就不太科学，所以自然也没有办法用科学的话来表达一个不科学的事儿。"——论"智能涌现"

KEY QUOTE (01:43:14):

"我觉得硬实力上其实没什么帮助。就是从工具生性的技能上来说，其实从物理到AI的转化是非常少的。但是我觉得可能非要问的话，我觉得可能主要的不能说能力，就是性格。"

KEY QUOTE (01:49:42):

"AI其实更多的是你有一个想法，然后你可以用一些数值去验证……这个反而和做物理很像……更像那个时代的物理，就是那个时代理论和实验不分家，没有什么理论物理学家、实验物理学家，你就是搞物理，就是搞物理的。"

数据点

- 伯克利博后仅约两周就辞职加入Anthropic（入职前已与Anthropic在谈）
- Anthropic内部有专门的interp（可解释性）团队

- Scaling law描述了模型在perplexity指标上随模型大小和数据量提升的规律
- 热力学第一定律、第二定律、克拉伯龙方程在历史上最初都是经验规律

8. Anthropic岁月：文化与强化学习 (01:50:08 – 02:12:25)

背景

深度讨论Anthropic的组织文化、决策机制，coding如何成为战略重点，以及姚顺宇的入职经历。

核心论点

姚顺宇揭示了Anthropic执行力的组织密码：技术一号位和公司决策人是同一个人——既有技术公信力（能让研究员信服），又有公司决策权（能为公司负责）。Jared Kaplan和Sam McCandlish同时是联合创始人，Dario的CEO角色是“配合而非阻碍”。这个模式的前提极为苛刻——联合创始团队无一人离开，这群人“是一块儿趴过战壕的人”。

他对比了三种组织模式：Anthropic（top-down、赌一件事）、Google（bottom-up、减少赌的成分）、OpenAI（Ilya离开后失去top-down能力）。

Coding优势的起源可能是偶然的（Claude 3发布后Twitter上讨论coding比GPT-4强），但Anthropic对市场反馈“非常reactive”，收到信号就全力扑上。

Coding对AI研究的双重战略价值：(1)形成研究飞轮；(2)coding是模型使用工具和环境交互的优质抽象——回归信号清晰且数据充分。

他的RL研究哲学：“把简单的事儿做的比谁都干净是最关键的。”

关于入职时机：“大家肯定已经看到这个事儿能做成且重要，但是不太清楚怎么去把它做成。然后我去的时候是跟大家一起去研究怎么把它做成。”

KEY QUOTE (02:01:28):

“实行top-down其实有一个很难的点，就是你做技术的决策人必须也得是公司本身的决策人。首先就是你技术上得能服众……另一方面就是你得是公司的决策人，你得能为这个公司负这个责任。”

KEY QUOTE (02:05:26):

“那是一群真正一起打过仗的人。……他们是一块儿趴过战壕的人，我觉得互相之间的信任还是很关键的。有很多公司可能就是干着干着连这个小集体都团结不住了。”

KEY QUOTE (02:06:48):

"消费这个公司曾经也是没啥产品能力的，居然管两个模型叫一个名字。"——调侃Anthropic早期产品能力

KEY QUOTE (02:09:13):

"把简单的事儿做的比谁都干净是最关键的。"

KEY QUOTE (02:10:17):

"coding其实是模型使用工具和环境交互的一个很好的抽象。……这个抽象的好处在于，比如说这个回归信号清晰，然后数据充分，然后其实你是很难在别的场景下找到能同时有这两个特质的使用工具场景。"

数据点

- 面试Anthropic的时间约为2024年9月（O1发布前夕）
- 入职时Anthropic Horizon团队（强化学习大组）约10-11人，整个公司约700-800人
- 同时联系了Anthropic、OpenAI和Google DeepMind三家
- DeepMind面试速度太慢，未进入最终考虑；OpenAI"没有找到特别合适的事和人"
- 面试时有两个组可选：模型评测和强化学习，选择了RL因为"更加不明朗"
- Andrej Karpathy的nanoGPT——姚顺宇面试前手搓该项目作为准备
- Claude 3.5有两个版本：6月版和10月版，官方均叫3.5
- Claude 3.7是Anthropic后训练的分水岭——从3.7开始后训练进入系统化阶段
- Anthropic联合创始人团队至今无一人离开

9. 从物理到AI的跨越 (02:12:41 – 02:36:39)

背景

讨论预训练和后训练的范式现状、Anthropic的文化冲击与离职原因，以及AI安全的根本性挑战。

核心论点

关于AI是否到达平台期，平台期有两种可能——技术本身到了极限，或者你想让模型干的事到了平台期。现在的情况是后者——"模型还是一个非常聪明的小孩，你其实可以教他很多东西，但是我们人类作为老师现在还不知道下一个东西该教什么。"

他坦诚了认知转变：在Claude 3.7时期曾相信预训练"party is over"，但后来"发现其实还有做的空间。"

算法技巧依赖基础设施——不同公司的infra差异导致算法设计完全不同，分享具体技巧"没用，反而会误导他人。"

关于AI安全，姚顺宇给出了与Anthropic官方立场直接冲突的观点：Dario的"先有最前沿模型才有话语权"策略是**"非常幼稚的，不会发生。"** 他提出核武器式的多边制衡方案。

离职原因三层分解：最大原因（想学Anthropic不做的事——多模态生成、底层工程）、文化变化、Dario反华立场（约40%，"dealbreaker但不是controlling的原因"）。

对AI本质的根本判断："AI本质上是简单的。它本质上简单的点在于他能做实验。"

语言模型的个人英雄主义时代已经过去了。"这个世界在推着我们前进，而不是我们在推着这个世界前进。"

KEY QUOTE (02:16:18):

"我觉得到达平台期有两种可能性。第一种可能性是技术本身到达了……另一种可能性是你想干的事儿到平台期了，我觉得现在就是后者。"

KEY QUOTE (02:16:50):

"模型还是一个非常聪明的小孩，你其实可以教他很多东西，但是我们人类作为老师现在还不知道下一个东西该教什么。"

KEY QUOTE (02:17:42):

"AI在现在最近这几年这事儿本身是一个不可阻挡的事儿。它不在于你这个人去干或者不干，你不干自也有别人一样能干出来的。"

KEY QUOTE (02:22:59):

"我觉得idea is cheap，想法是便宜的。很多想法其实很显然，所有人都知道。难的是怎么把实现，怎么把它变成一个小的可实现的步骤把它做出来。"

KEY QUOTE (02:31:14):

"这个世界在推着我们前进，而不是我们在推着这个世界前进。"

KEY QUOTE (02:33:35):

"核武器也是一个可以大家觉得可能有毁灭世界力量的事儿，但核武器最后最终受到控制的方法就是 *multiparty control*。大家有很多个有核武器的国家，他们互相都有毁灭对方的能力，所以通过这样一种制衡才稳定住。我觉得你要阻止AI干一些不好的事儿，可能最终是需要一种类似的机制来实现的。"

KEY QUOTE (02:35:18):

"AI本质上是简单的。它本质上简单的点在于他能做实验。它和比如说本质上难的东西，比如说物理，它的区别在于那个东西你没有那个能标下的实验数据，你就是理解不了那个能标下的理论。但是AI不被这个所限制。"

数据点

- Claude 3.7从开始研究到发布约4-5个月：研究约2-3个月，训练+基础设施约2个月
- Anthropic员工数在嘉宾离职时接近2000人，入职时约1000人左右，翻了一倍多
- 离开Anthropic的酝酿时间约1个月到1个多月
- Dario反华立场占离职原因约40%（嘉宾的公开场合说法）
- Claude 3.7时期他在RL中做agentic coding：环境制备、数据制备和算法稳定性问题
- OpenAI的Q*/Strawberry秘密项目在早期大家只知道名字，被认为是后训练+RL新范式

10. Google DeepMind与竞争格局 (02:37:33 – 02:58:16)

背景

讨论离职时的商业判断（及修正）、ML Coding和Long Horizon方向、Google复兴转折，以及AI产品形态的未来。

核心论点

姚顺宇坦诚了一个重大判断失误：离开时认为API/token是"差生意"（价格战），因此对Anthropic悲观。但"后来显然是我过度悲观了"——Anthropic通过产品创新走出差异化。

两个核心研究方向：**ML Coding**（AI自主研究闭环——写代码→跑实验→看结果→分析问题→提出新假设→设计新实验）和**Long Horizon**（在有限context下完成更长工作）。Long Horizon的核心哲学"**train is finite, but use is infinite**"来源于对人类记忆机制的观察——context很短，但能选择性遗忘和retrieve。

Google复兴的双引擎：Nano Banana（爆款产品带来用户）+ Gemini 3（模型能力留住用户）。现在Google市场份额约20%（嘉宾估计）。

对AI产品形态的根本性质疑："这个模型明明有那么多能力，但居然用的方法是chatbot，就是不太make sense。"

Google的制胜公式："找到一个最为简单的产品形态，大家都长一个样，他就疯狂给你卷技术，你就解不过他。"

"**现在谁的位置都不稳固。**AI的形态还有很长的路要走，没有到什么终局之战。"

选择Google DeepMind而非OpenAI的核心原因："感觉踏实做事的人没有DeepMind多，更没有Anthropic多。"

KEY QUOTE (02:37:43):

"我离开的时候，我对这个公司其实挺悲观的，但后来显然是我过度悲观了。"

KEY QUOTE (02:42:06):

"train is finite, but use is infinite."

KEY QUOTE (02:42:43):

"人的context其实很短。你现在问我昨天晚上吃了什么，我是一点也想不起来了。因为什么？因为它对我现在这个场景来说不关键。"

KEY QUOTE (02:55:47):

"Google传统上在产品就是有点慢。Google特别擅长的一件事是什么？是找到一个最为简单的产品形态，大家都长一个样，他就疯狂给你卷技术，你就解不过他。"

KEY QUOTE (02:57:14):

"现在谁的位置都不稳固。我觉得AI的形态还有很长的路要走，没有到什么终局之战。"

KEY QUOTE (02:58:16):

"这个模型明明有那么多能力，但居然用的方法是chatbot，就是不太make sense。"

KEY QUOTE (02:49:53):

"我觉得OpenAI最后没有去的一个转折原因还是我对它的文化是有比较大的担心的。就是感觉踏实做事的人没有DeepMind多，更没有Anthropic多。"

数据点

- Anthropic主要收入来源是API（卖token）（嘉宾离职时的判断）
- Google Gemini市场份额约20%（嘉宾粗略估计）
- 加入Google DeepMind时间是2025年9月底，在Gemini 3发布之前
- Gemini 2.5是业内感知到Google开始上道的转折点
- Nano Banana（Pixel 9 AI功能）是Google AI的爆款产品
- Claude Code起源于研究员Boris想提高工作效率的个人项目
- 中国AI lab在长文本方面做得很好，有一些让嘉宾惊讶的技巧
- 绝大多数普通用户不使用O系列模型，只使用普通GPT模型

11. 组织DNA与行业终局 (02:58:34 – 03:29:34)

背景

讨论AI大实验室的组织结构差异、benchmark饱和、TPU vs GPU架构、硅谷新兴AI实验室浪潮，以及中美产品路径分化。

核心论点

姚顺宇提出了统一框架："预训练和SFT本质上也没什么区别"——从数学框架看两者都是RL的子集。区别在数据工程：预训练要求分布广但质量要求低，后训练要求分布窄但质量要求极高。

关于benchmark饱和：SWE-bench各家80%+，GPQA从十几%到80%+。"光靠打这种公众认知的模型能力benchmark，其实已经没啥太大的意思了。""幸亏没有人超过83（SWE-bench），谁超过谁尴尬。"

冲浪理论的完整表述："现在大家每个人都是冲浪的人，本质上是一个浪，而不是你那个冲浪的人。"

对硅谷new AI lab："我觉得绝大多数的新lab都会死。"

关于中美产品分化的根本原因："在美国挣钱太容易。挣钱太容易的时候，你就不会费脑筋去想怎么挣钱。"而中国C端产品"一开始不挣钱，但一旦开始挣钱你就拦不住他。"他认为ByteDance是一家被严重低估的公司。

关于组织管理："组织运行得好不好，看起来是组织的问题，但其实归根结底是技术leader的问题。"

关于系统性工作："每一个系统的每一个平台的框架都是很容易被hack的。所以你总可以做一些事儿，让你的指标看起来很好看。"

关于Continual learning和long horizon的统一视角："KV cache本身也是一种权重"——两者没有本质区别。

"一万个人有一万个世界模型"——概念定义完全不清晰。

KEY QUOTE (03:01:31):

"预训练和SFT本质上也没什么区别。你无非就是把你拿到的那些数据当成你的ground truth……从某种意义上来说，预训练和SFT是强化学习的一个子集。"

KEY QUOTE (03:05:08):

"现在大家每个人都是冲浪的人，本质上是一个浪，而不是你那个冲浪的人。AI这个事情本身是这个浪它会往前走，不管你冲不冲这个浪，这个浪都会拍到岸上。"

KEY QUOTE (03:07:32):

"光靠打这种公众认知的模型能力benchmark，其实已经没啥太大的意思了。SWE-bench大家都打到80多，幸亏没有人超过83……谁超过谁尴尬。"

KEY QUOTE (03:11:29):

"一万个人有一万个世界模型。首先我不知道什么叫做一个世界模型。其次就是每个人在说他们做的世界模型的时候，可能也在说不一样的事儿。"

KEY QUOTE (03:15:22):

"每一个系统的每一个平台的框架都是很容易被hack的。所以你总可以做一些事儿，让你的指标看起来很好看。但是一个值得信赖或者踏实的人，他其实是会想自己做的这件事儿如果效果好的话是不是真的。"

KEY QUOTE (03:19:43):

"组织运行得好不好，看起来是组织的问题，但其实归根结底是技术leader的问题。最好的那个状态往往都是最不稳定的一个状态，就很容易往不好的那个方向滑。所以得有一个leader来控制这个事儿。"

KEY QUOTE (03:26:39):

"在美国挣钱太容易。挣钱太容易的时候，你就不会费脑筋去想怎么挣钱。"

KEY QUOTE (03:27:31):

"中国C端产品……一开始不挣钱，但是一旦他开始挣钱你就拦不住他。他就是真的能形成自己的那个圈，圈转起来的时候你再想往里插就插不进去了。"

KEY QUOTE (03:23:41):

"我觉得绝大多数的新lab都会死。有些new lab就是……我就完全不知道他们到底要干嘛，然后这两人其实已经远离这个专业好久了。"

KEY QUOTE (03:17:50):

"在公司做research和在学术界是完全不一样的心态。在学术界做research本质上是一个人吃饱全家不愁的状态……但是在一个公司里，你其实更多的时候是我得为这个公司负责。"

数据点

- SWE-bench各模型打到80%+；OpenAI发布post称达到83%，但部分题目定义不良
- GPQA benchmark：从十几%被DeepSeek打到80%+
- Google DeepMind近期发布：Gemini 3 Deep Think、Gemini 3.1 Pro
- Koray Kavukcuoglu — Google DeepMind CTO兼Google SVP
- Sergey Brin — Google联合创始人，DeepMind重大决策最终拍板人
- Demis Hassabis — 管更多偏science方向如药物设计、Isomorphic Labs
- GPU架构（Hopper/H100）：一个pod内8张卡NVLink两两互联
- TPU架构：三维torus拓扑设计，好的compiler/sharding可获更大等效存储空间
- Meta正主动从字节跳动挖人

12. 个人哲学、职业建议与快问快答 (03:29:40 – 03:47:48)

背景

访谈收尾部分——对年轻人的职业建议、个人沟通哲学、"老登"概念辨析，以及快问快答。

核心论点

重申核心主张："靠谱，就是做事儿细，然后对自己做的事儿负责任"——"你说那些东西有多需要脑子，我觉得都是一些本科生就能干的活。"

24小时面试设计三重考察：(1)能否有效利用AI工具，(2)是否真正理解AI做了什么，(3)是否愿意熬夜——衡量对机会的看重程度。

对年轻人的核心建议："纯做语言模型已经不是一个蓝海了。我觉得晚了，就是末班车已经发车了。"但AI仍有很多蓝海——多模态生成、机器人、AI辅助科学。

"老登"理论：年长者分两种——"德高望重"（少指手画脚、培养年轻人）和"老登"（自己不懂还爱指手画脚）。为什么越来越恨老登："可能就是当你自己有越来越多判断的时候，那些蠢的人就显得更蠢。"

直接表达的哲学："直接表达自己的想法是一个短期一定会有人恨你，但长期大家会欣赏你的事。"

Anthropic和Google提供了互补的学习经历：前者纵向深透（一个方向），后者横向宽广（不同方向、不同人、不同视角）。

在快问快答中：人生之书汤川秀树自传、小说《来自新世界》、关键赌注是long horizon、影响AI论文为Seq2Seq和Scaling Laws、最喜欢寿司、不知道MBTI、地点夏威夷、知识点"别相信老登"。

KEY QUOTE (03:29:42):

"我觉得这个行业最重要的特质就是靠谱，就是做事儿细，然后对自己做的事儿负责任，这是最重要的特质。你说那些东西有多需要脑子，我觉得都是一些本科生就能干的活。"

KEY QUOTE (03:33:45):

"纯做语言模型已经不是一个蓝海了。我觉得晚了，就是末班车已经发车了。我感觉我入行就是那个末班车。"

KEY QUOTE (03:39:55):

"直接表达自己的想法是一个短期一定会有人恨你，但长期大家会欣赏你的事。"

KEY QUOTE (03:40:32):

"我觉得他说的话用Pauling的话来说就是not even wrong。因为不良好定义，你很难说他说的是对是错。就是有一天可能有一个不一样的方式发生了，他就可以跳出来，我当年说过。"

KEY QUOTE (03:41:47):

"我觉得人年纪大了不一定会变成老登的。人年纪大了会变成两种状态，一种状态叫做德高望重，就是他可能会少指手画脚，还会花自己的力气去培养年轻人。另一种人就是老登，自己也不懂，还爱指手画脚。"

KEY QUOTE (03:45:05):

"别相信老登。"

KEY QUOTE (03:45:27):

"我以前可能没有这么恨老登，后来就变得越来越恨老登。为什么？可能就是当你自己有越来越多判断的时候，那些蠢的人就显得更蠢。"

KEY QUOTE (03:47:00):

"我觉得这个名字有点正常的，太平庸了……可能放在十年以前是一个很独特的视角。"

数据点

- 24小时面试：候选人从0到1完成强化学习项目
- 语言模型末班车大约在2023-2024（嘉宾入行时间）
- 职业路径：Stanford物理博士 → Anthropic → Google DeepMind
- 推荐书籍：汤川秀树自传（Hideki Yukawa）；小说：《来自新世界》（贵志祐介）
- 最快问答：寿司、夏威夷、不知道MBTI、关键论文Seq2Seq和Scaling Laws、关键赌注horizon
- 工作室名称"语言即世界"——嘉宾评价"放在十年以前是一个很独特的视角"

跨领域主题 (Cross-Cutting Themes)

1. AI的集体主义时代：个人英雄主义的终结

这是访谈最核心的哲学主张。姚顺宇反复论证，Transformer之后AI研究已进入系统性工程阶段，靠单打独斗产生突破的时代已经过去。核心能力是"靠谱"——对自己做的事有清晰的自我认知。"冲浪"比喻贯穿访谈始终：AI浪潮本身是不可阻挡的动量，"这个世界在推着我们前进，而不是我们在推着这个世界前进。"

Examples across topics:

- From 开场 (00:45): "现在就是大家每个人都是冲浪的人，本质上是一个浪，而不是你那个冲浪的人。"
- From 从物理到AI (02:17:42): "AI在现在最近这几年这个事儿本身是一个不可阻挡的事儿。"
- From 组织DNA讨论 (03:05:08): "AI这个事情本身是这个浪它会往前走，不管你冲不冲这个浪，这个浪都会拍到岸上。"
- From 快问快答 (03:28:42): "我觉得我个人英雄主义时代已经过去了。"

2. 范式成熟度的三层分化：语言→多模态→机器人

姚顺宇将AI各领域按范式成熟度分为三层：(1)自然语言处理——范式确定（预训练+后训练），工程问题为主；(2)多模态生成——范式未固定，仍是科学问题；(3)机器人——处于feature engineering阶段，连GPT-1时刻都还没到。

Examples across topics:

- From 模型进步 (33:26): 自然语言生成科学上比较清楚；多模态生成是另一个科学问题还没有解决的领域。
- From 豆包讨论 (50:16): "C-Dance"并没有体现出什么范式上的改变。"
- From 机器人 (01:06:19): "机器人我觉得没到那个阶段。"
- From 范式框架 (01:08:30): "对我来说不管机器人还是多模态生成都没到这个点。"

3. 资源约束与创新的辩证关系：算力劣势逼出蒸馏创新

中国在算力上的劣势反而催生了独特的创新路径。姚顺宇区分了"硬蒸馏"和"软蒸馏"，将中国的多模型异构训练定位为"真正multi-agent训练的先驱"。

Examples across topics:

- From 中美对比 (53:39): "中国确实在实际的算力资源上来说是占很大劣势的。但是这个很大的劣势可能反而逼出了一些有趣的事儿。"
- From 蒸馏讨论 (56:07): "中国的实验室成为了做multi-agent训练的先驱，而且是真正的multi-agent。"
- From 字节评价 (57:38): 字节是蒸馏做得比较少的公司，模型比较有特点。
- From 中美产品分化 (03:26:39): 美国"挣钱太容易"所以没有发展出中国式C端产品模式。

4. 组织DNA决定AI战略：Top-Down vs Bottom-Up的不同道路

三种组织模式贯穿访谈：Anthropic的top-down（技术一号位make bet，全公司对齐），Google的bottom-up（多方向并行、减少赌的成分），OpenAI的过渡态（Ilya离开后失去top-down能力）。

Examples across topics:

- From Anthropic组织 (02:01:28): 技术决策人必须同时是公司决策人——技术上能服众且能为公司负责。
- From Anthropic创始团队 (02:05:26): 这是一群"一块儿趴过战壕的人"，联合创始人团队无一人离开。
- From Google组织 (02:03:45): 大公司策略是"尽量减少做赌的成分"。
- From 组织领导力 (03:19:43): "最好的那个状态往往都是最不稳定的一个状态。"

5. AI产品交互形态远未定型：Chatbot不是终局

姚顺宇对"chatbot是终极形态"的假设提出尖锐批评，认为模型能力远未被当前交互方式充分发挥。

Examples across topics:

- From AI原生应用 (15:14): "从某种意义上来说，ChatGPT其实是搜索的一个延伸。"
- From 产品形态 (02:58:16): "这个模型明明有那么多的能力，但居然用的方法是chatbot，就是不太make sense。"
- From AI终局 (02:57:14): "现在谁的位置都不稳固。"

6. 选择哲学：追求本质的难，而非表面的新

姚顺宇的整个职业生涯都遵循同一原则："不喜欢做已经会了的事情。"他区分了"本质的难"（科学问题、范式突破）和"表面的难"（工程复杂度）。

Examples across topics:

- From 个人成长 (01:11:10): "我这个人的个性就是总是爱干一些自己不太会的事儿。"
- From 物理转方向 (01:26:31): 放弃了前景广阔的凝聚态方向。
- From 挑战哲学 (01:27:51): "如果是为了被折磨而被折磨，那这个人就是有心理疾病。但是如果一个人是为了学习更多的东西，丰富自己的经历和能力而被折磨，我觉得是值得的。"

7. Scaling Law未死：从简单堆砌到系统优化

模型进步速度没有放缓，但进步的表现形式在变化。大部分"撞墙"感受来自数据瓶颈或工程bug，而非真正的科学极限。

Examples across topics:

- From 模型进步 (26:26): "这个模型学东西的能力越来越强了。"
- From 三种撞墙 (27:49): 定义了三种"墙": fundamental limit、data wall、bug。
- From 认知转变 (02:15:12): 从相信预训练快结束了到"发现其实还有做的空间。"
- From 数据驱动 (29:05): "很多时候修好一个bug带来的进展是远大于一些很神奇的技巧的。"

矛盾与未解问题 (Contradictions & Open Questions)

#	Tension / Question	Context	Resolution Status
1	"AI不太需要脑子" vs "从不知道到知道有一个gap需要花时间"	(03:29:34) vs (03:35:26)	层次区分——对纯智商要求不高，但理解系统运作细节需要时间
2	"我对Claude 3.7的贡献没那么重要" vs 也曾追求产品影响力	(02:17:42) vs (02:27:38)	反映不同阶段优先级切换——Anthropic时追求impact，DeepMind时追求自由
3	"预训练快party is over了" → "后来发现其实还有做的空间"	(02:14:50) → (02:15:12)	认知演变过程，嘉宾明确承认想法经历过摇摆
4	"Anthropic从产品角度我挺悲观的" → "后来显然是我过度悲观了"	(02:37:43) → (02:38:07)	嘉宾清楚承认判断错误并修正
5	公开benchmark差异是"噪声" vs 实际使用时仍有可感知差异	(07:08) vs (08:03)	区分两种评估维度，论证模型评估进入新阶段
6	"成年人很难真的崇拜一个人" vs Hinton可能是英雄级别人物	(03:37:47) vs (03:37:58)	区分"崇拜"和"敬佩"
7	中国AI人才"本质上比美国更好" vs 技术"还没真的追上美国"	(21:13)	区分人才质量和当前技术水平
8	下一个范式级变化是什么？	贯穿访谈	Unresolved——多模态生成和long horizon是最有希望的方向
9	AI交互的下一个形态是什么？	(02:58:16)	Unresolved——确信chatbot不是终局但无法具体说明
10	机器人何时迎来GPT-1时刻？	(01:08:30)	Unresolved——需要类似Transformer的范式突破
11	模型能力的"商品化"趋势会加速还是逆转？	(25:38)	Unresolved——差异越来越来自"想象不到的事"

预测总结 (Predictions Summary)

#	Prediction	Time Horizon	Confidence	Conditions / Caveats
1	2026年内实现"train with finite context, use as infinite context"	2026年内	High	多条技术路线都可能跑通
2	预训练在接下来四个月内会继续有进展	4个月	High	基于当前实验观察趋势
3	预训练和后训练都还没有到达平台期——瓶颈在于"不知道教什么"	Ongoing	Medium	取决于是否出现技术本身的极限
4	AI将在6-12个月内能端到端完成AI研究任务	6-12个月	Low	嘉宾承认"这话不太良好定义"
5	ML coating在未来几个月看到曙光	2026年中至年末	Medium	取决于Google内部推进
6	Long horizon未来几个月到一年有进展	几个月到一年	Medium	全行业共识方向
7	程序员不会一夜被全替代，每6个月AI攻克一批能力	持续演进	Medium	取决于模型在复杂规划等进化速度
8	范式级变化将来自"非确定性"方向——多模态生成	1-3年	Medium	突破需从不确定性高的方向来
9	聊天机器人不是AI终极交互形态	Unspecified	Tentative	嘉宾承认是直觉判断
10	绝大多数硅谷new AI lab会死掉	1-3年	High	部分lab缺乏清晰方向
11	语言模型方向窗口期已关闭——末班车已发	现在（2026）	High	嘉宾认为2023-2024是末班车
12	AI发展已不可阻挡	Ongoing	High	"你不发展别人会发展"
13	多模态生成可能出现范式级变化	中长期	Medium	属于"非确定性"方向
14	美国公司短期难复制字节跳动式C端产品模式	中长期	Medium	美国to B利润太高
15	美国AI公司未来会转向优化日常/生活场景	Unspecified	Implied	智能上限竞争饱和后
16	机器人方向未来很重要但尚未找到自己的路	Unspecified	Medium	需要范式突破

金句全集 (Complete Quote Collection)

AI行业特质与个人哲学

1. (00:45) "AI这个事儿本来也不太需要脑子……我觉得这个行业最重要的特质就是靠谱，就是做事儿细，然后对自己做的事儿负责任，这是最重要的特质。"
2. (00:45) "现在就是大家每个人都是冲浪的人，本质上是一个浪，而不是你那个冲浪的人。"
3. (03:29:42) "你说那些东西有多需要脑子，我觉得都是一些本科生就能干的活。"
4. (03:39:55) "直接表达自己的想法是一个短期一定会有人恨你，但长期大家会欣赏你的事。"
5. (02:22:59) "我觉得idea is cheap，想法是便宜的。很多想法其实很显然，所有人都知道。难的是怎么把实现，怎么把它变成一个小的可实现的步骤把它做出来。"
6. (02:09:13) "把简单的事儿做的比谁都干净是最关键的。"
7. (01:11:10) "我这个人的个性就是总是爱干一些自己不太会的事儿。"
8. (01:27:51) "如果为了被折磨而被折磨，那这个人就是有心理疾病。但是如果一个人是为了学习更多的东西，丰富自己的经历和能力而被折磨，我觉得是值得的。"
9. (01:15:25) "我从那件事儿得到的人生最重要的道理就是胆子要大。你不争取是永远得不到的，争取了也有可能得不到，但不争取就绝对得不到。"
10. (03:41:47) "人年纪大了不一定会变成老登的……一种状态叫做德高望重……另一种人就是老登，自己也不懂，还爱指手画脚。"
11. (03:45:05) "别相信老登。"
12. (03:45:27) "我以前可能没有这么恨老登，后来就变得越来越恨老登。为什么？可能就是当你自己有越来越多判断的时候，那些蠢的人就显得更蠢。"
13. (03:28:42) "我觉得我个人英雄主义时代已经过去了。所以也没有什么英雄。"

AI发展阶段与模型能力

1. (05:47) "对我来说确实在AI进入到了一个阶段。我觉得大家都已经开始不那么担心一件事AI是不是能够做得到，而是担心这件事儿是不是被良好定义。"
2. (07:08) "大家都在80%附近，那个附近数字高一点低一点，其实是主要是noise，就主要是是噪声而不是信号。"
3. (26:26) "我觉得我个人得到的感受是这个模型学东西的能力越来越强了。"
4. (02:16:50) "模型还是一个非常聪明的小孩，你其实可以教他很多东西，但是我们人类作为老师现在还不知道下一个东西该教什么。"
5. (29:05) "很多时候修好一个bug带来的进展是远大于一些很神奇的技巧的。"

6. (02:35:18) "AI本质上是简单的。它本质上简单的点在于他能做实验。"

Coding革命与程序员未来

1. (38:36) "真正去输出code, 我觉得模型比人的能力强太多了……保守估计模型写的超过90%, 不保守的可能就是99或者100。"
2. (45:10) "过去大家往往会觉得最智力上有挑战的工作……越是这些事儿其实应该越容易做好。因为你一旦想清楚这个事儿怎么去评价, 你就知道怎么训练。"
3. (47:09) "AI是一个很centralized的technology, 它会让少部分人变得更强大, 但会让大部分人失去他们的独特价值。"
4. (41:43) "我觉得开发的速度变快了之后, 就越试越想试……拿去问一下Claude或者Gemini, 这可能5秒钟就告诉你结果, 你就接着干了。"

组织文化与行业竞争

1. (02:01:28) "实行top-down其实有一个很难的点, 就是你做技术的决策人必须也得是公司本身的决策人。"
2. (02:05:26) "那是一群真正一起打过仗的人……他们是一块儿趴过战壕的人。"
3. (03:19:43) "组织运行得好不好, 看起来是组织的问题, 但其实归根结底是技术leader的问题。"
4. (03:15:22) "每一个系统的每一个平台的框架都是很容易被hack的。"
5. (02:55:47) "Google特别擅长的一件事是什么? 是找到一个最为简单的产品形态, 大家都长一个样, 他就疯狂给你卷技术, 你就解不过他。"
6. (02:57:14) "现在谁的位置都不稳固。AI的形态还有很长的路要走, 没有到什么终局之战。"

中美AI与产品

1. (53:39) "中国确实在实际的算力资源上来说是占很大劣势的。但是这个很大的劣势可能反而逼出了一些有趣的事儿。"
2. (55:01) "硬蒸馏就是……从Claude里面取出一堆它生成的token, 然后强行在上面做训练。首先商业上也不是很道德了, 然后智力上来说也比较愚蠢。"
3. (56:07) "中国的实验室成为了做multi-agent训练的先驱, 而且是真正的multi-agent。"
4. (01:02:13) "客气的说可能是全世界最好的之一, 不客气的说我觉得就是全世界最好的。"
5. (03:26:39) "在美国挣钱太容易。挣钱太容易的时候, 你就不会费脑筋去想怎么挣钱。"
6. (03:27:31) "中国C端产品……一开始不挣钱, 但是一旦他开始挣钱你就拦不住他。"

物理学与人生教训

1. (01:38:34) "人这一辈子也没多长, 为什么要把自己的时间浪费在伺候老登身上?"

2. (01:38:47) "花了五年学了很多知识，买了一个大教训。"
3. (01:39:06) "大教训就是要做实验，要要有做有比较客观评价标准的事儿。"
4. (01:40:33) "我后来就发现我蒙蔽不了自己，骗不了自己。"
5. (01:40:06) "达到外界的标准是像训练模型一样。"

AI产品形态

1. (13:43) "他让大家意识到了这件事可以做……做一个很长很长老horizon的这种工作。"
2. (02:58:16) "这个模型明明有那么多的能力，但居然用的方法是chatbot，就是不太make sense。"
3. (02:42:06) "train is finite, but use is infinite."

AI安全

1. (02:33:35) "核武器最后最终受到控制的方法就是multiparty control……我觉得你要阻止AI干一些不好的事儿，可能最终是需要一种类似的机制来实现的。"

职业建议

1. (03:33:45) "纯做语言模型已经不是一个蓝海了。我觉得晚了，就是末班车已经发车了。我感觉我入行就是那个末班车。"

认知论

1. (01:44:31) "我觉得这世界上所有东西都是黑盒。"
2. (01:47:01) "首先这个话就不太科学，所以自然也没有办法用科学的话来表达一个不科学的事儿。"
3. (03:11:29) "一万个人有一万个世界模型。"

家庭与成长

1. (01:18:41) "当你没有办法理解别人在干什么的时候，别指手画脚。"
2. (01:11:39) "我感觉这个竞赛……就是underdog。厉害，用当时话说我感觉就是光脚的不怕穿鞋的。"

物理与AI方法论

1. (01:22:21) "物理科研和AI其实也是一样……AI也是你有一个想法，有一个理解，去设计一些实验验证你的理解是不是对的。"
2. (01:35:44) "读书不在于读得多，而在于读得深。"
3. (01:36:11) "别太相信理论，别太相信纯理论。"

4. (01:49:42) "AI其实更多的是你有一个想法，然后你可以用一些数值去验证……更像那个时代的物理……你自己可以做实验，然后也可以做理论的推测。"
 5. (03:01:31) "预训练和SFT本质上也没什么区别……预训练和SFT是强化学习的一个子集。"
-

阅读指南 (Reading Guide)

Reader Profile	Recommended Sections	Estimated Time
Executive / Decision-maker	执行摘要, 预测总结, Segment 2 (模型商品化与创业生存策略)	10 min
AI Researcher / Engineer	Segment 3 (Open Cloud与产品形态), Segment 4 (Scaling Laws), Segment 9 (预训练与后训练范式), Segment 11 (组织DNA与基准饱和)	30 min
Product Manager / Entrepreneur	Segment 2 (模型商品化), Segment 5 (个人成长与决策模式), Segment 7 (AI认识论), Segment 12 (职业建议)	20 min
Chinaverse AI Practitioner	Segment 4 (中美对比与豆包), Segment 11 (中美产品分化), 跨领域主题#3 (资源约束与创新)	15 min
Career Changer / Student	Segment 5 (从物理竞赛到清华), Segment 6 (从物理到AI的跨越), Segment 12 (职业建议与快问快答)	20 min
Full Deep Dive	完整报告	45+ min

快速导航提示：

- 如果你只有10分钟：先读"执行摘要"（把握全局叙事），然后跳到"预测总结"表格（18条预测一览），最后扫一眼"金句全集"中标注为high impact的条目。
- 如果你关心中美AI竞争：从Segment 4（Scaling Laws与中美对比）开始，结合跨领域主题#3（资源约束与创新），跳到Segment 11（中美产品分化）。
- 如果你考虑AI行业求职：从Segment 12（职业建议）开始，回溯到Segment 8（Anthropic组织文化）了解两种组织的差异，再看Segment 9（离开Anthropic的原因与Google DeepMind的选择）。

本报告基于张小珺对姚顺宇的3小时47分钟深度访谈（2026年5月），由interview-based-learning系统自动生成。所有引用均为逐字稿原话，时间戳精确到秒。